Прогноз космологического красного смещения по фотометрическим признакам

Научные руководители:
Герасимов С.В., к.ф.-м.н. Мещеряков А.В.

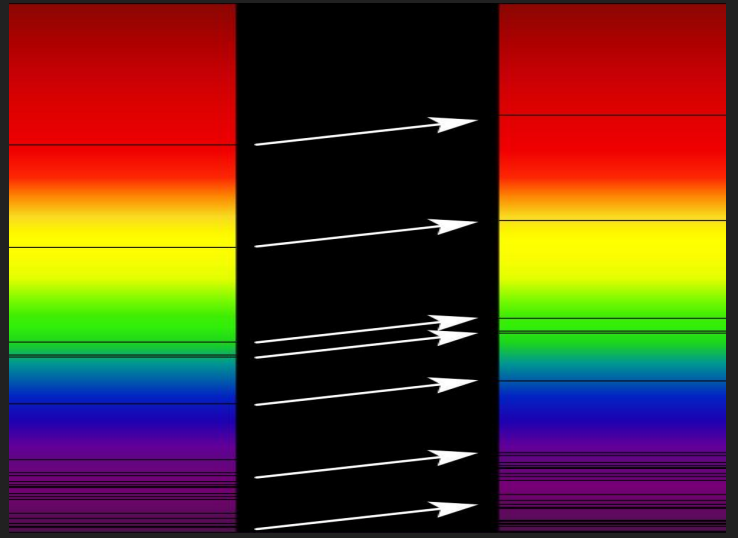
Выполнил: Кадыров Э.Э., 320 группа

Введение

- Космологическое красное смещение — наблюдаемое увеличение длины волны излучения астрономических объектов, обусловленное расширением Вселенной

$$z = \frac{\lambda_{dst} - \lambda_{src}}{\lambda_{src}}$$

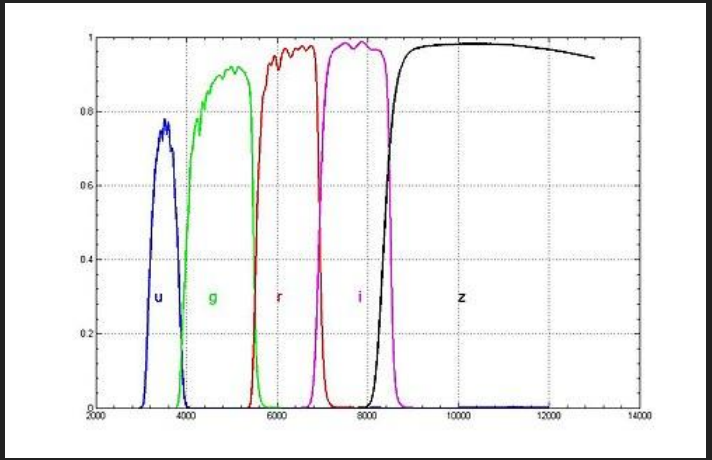
- Собираются новые обзоры неба, строятся интерактивные карты
  - Vera C. Rubin Observatory, Large Survey Synoptic Telescope (LSST) – 2025
  - Kitt Peak National Observatory, Dark Energy Spectroscopic Instrument (DESI) – 2021
  - Apache Point Observatory, Sloan Digital Sky Survey (SDSS) – 2000

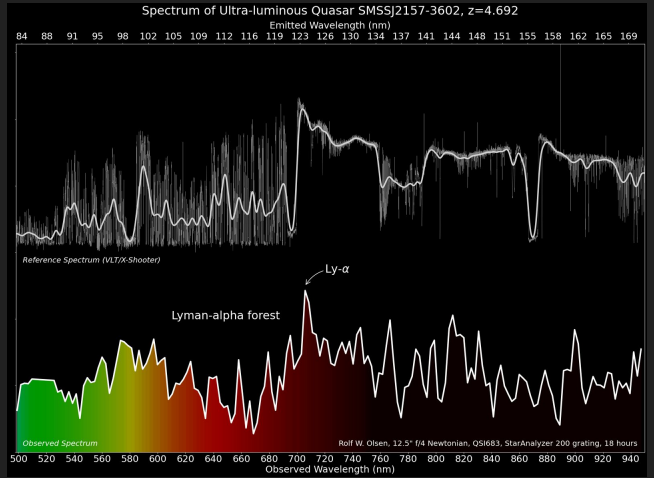




Введение

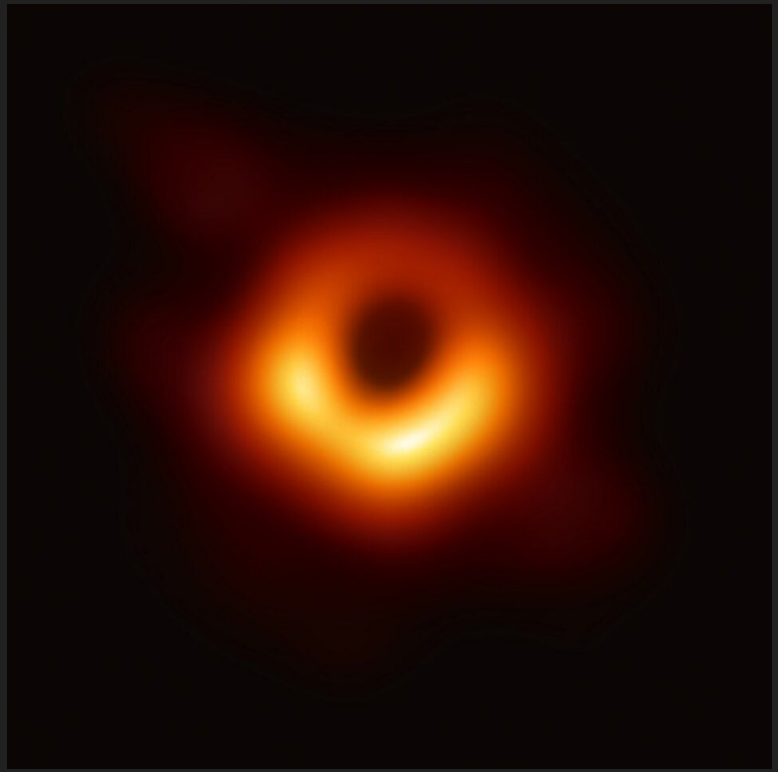
- Фотометрическое измерение – измерение яркости объекта в широких диапазонах длин волн (фильтрах – u, g, r, i, z)
- Спектроскопическое измерение – измерение распределения яркости по длинам волн с высоким спектральным разрешением





Введение

- Рентгеновский объект – объект, излучающий большую часть энергии в рентгеновском диапазоне
- Примеры:
  - активные ядра галактик
  - черные дыры
  - квазары
  - скопления галактик



Галактика M87

Введение. Актуальность

Точное определение photo-z необходимо [1] для:

- изучения эволюции Вселенной (дальние объекты видны в более раннюю эпоху Вселенной)
- определения светимости, массы объектов
- анализа структуры Вселенной

Вычисление космологического красного смещения дешевле и эффективнее через фотометрию, чем через спектроскопию:

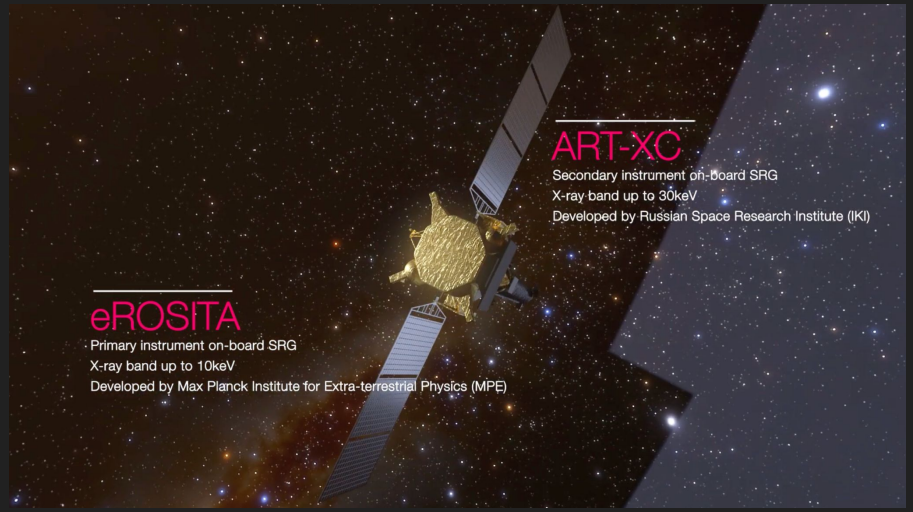
- не требуется непрерывное наблюдение за одиночным объектом
- наблюдение за миллионами объектов одновременно

[1] Newman, J. A., & Gruen, D. (2022). *Photometric Redshifts for Next-Generation Surveys*. Annual Review of Astronomy and Astrophysics, 60, 363–414

Введение. Актуальность

Актуальность изучения рентгеновских объектов [2]:

- у России самые глубокие обзоры восточной половины неба – СРГ/eРОЗИТА
- требуется карта этих объектов
- текущая версия карты получена случайным лесом – требуется улучшение на основе последних обзоров, современных достижений машинного обучения



[2] Мещеряков, А., Борисов, В., Хорунжев, Г., Васильев, С., Бельведерский, М., Медведев, П., Гильфанов, М., Сазонов, С., Буренин, Р., Бикмаев, И., Хамитов, И., Машечкин, И., Сюняев, Р. (2022) – SRGz: Методы машинного обучения и свойства каталога оптических компаньонов точечных рентгеновских источников СРГ/eROSITA в области покрытия DESI Legacy Imaging Surveys.

Постановка задачи

Исследование и разработка алгоритмов машинного/глубокого обучения для предсказания photo-z **рентгеновских источников**

Обзор решений. Цель обзора

Поиск существующих методов решения задачи photo-z для обоснования выбора:

- набора данных
- алгоритмов машинного/глубокого обучения
- метрик качества

Обзор решений. Сложность астрономических данных

- Неравномерное распределение фотометрических и спектроскопических признаков (domain shift)
- Тест Teddy: A – обучающая, B/C/D – тестовые [3]
- Цель – проверить экстраполяционную устойчивость моделей

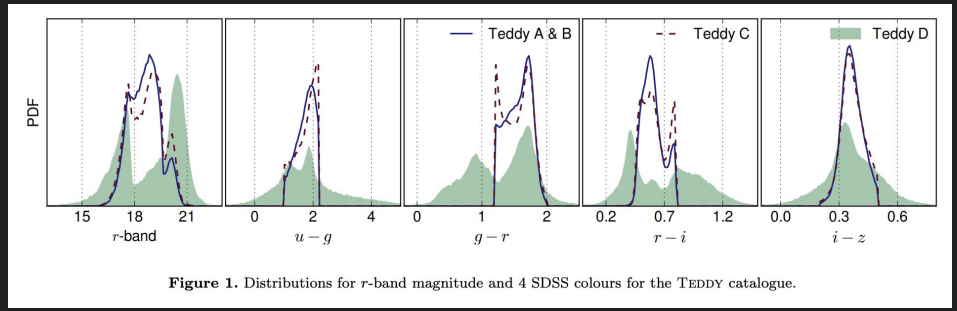


Figure 1. Distributions for r-band magnitude and 4 SDSS colours for the TEDDY catalogue.

[3] Beck et al., 2017 — On the realistic validation of photometric redshifts, or why Teddy will never be Happy

Обзор решений. Сложность астрономических данных

- Зашумленность фотометрических измерений
- Спектроскопия делается для ярких объектов
- Тест Happy: A – обучающая, B/C/D – тестовые [3]
- Цель – проверить устойчивость моделей к шуму, качество обучения на ярких галактиках

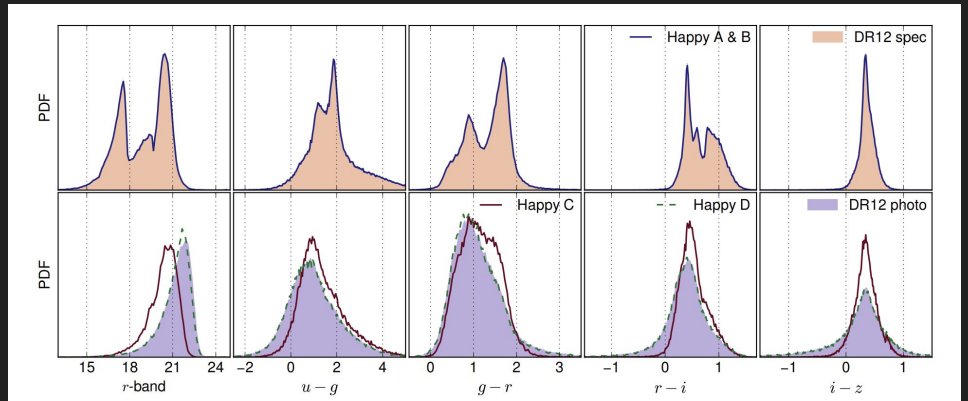


Figure 2. Distributions for magnitude in r-band and 4 colors for the HAPPY catalogue compared with the full spectroscopic (red) and photometric (purple) distributions from SDSS-DR12.

[3] Beck et al., 2017 — On the realistic validation of photometric redshifts, or why Teddy will never be Happy

Обзор решений. Сложность астрономических данных

- Зашумленность фотометрических измерений
- Сдвиг ослабления (Attenuation Bias) – модель стремится к условному среднему [4]

$$\mathbb{E}[y_{\text{pred}} | x_{\text{obs}}]$$

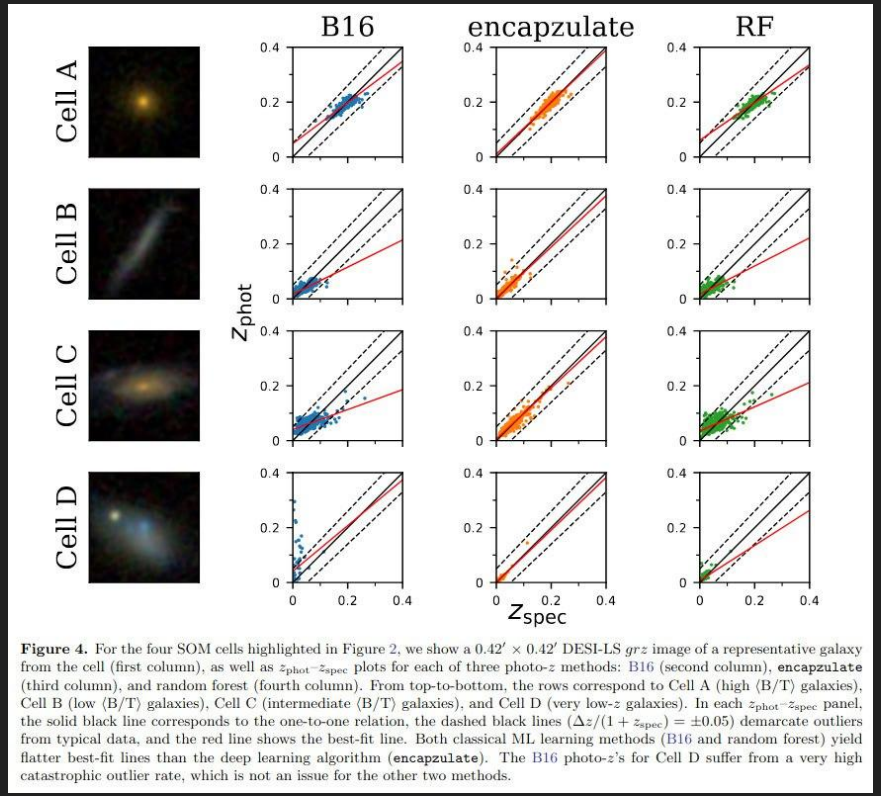


Figure 4. For the four SOM cells highlighted in Figure 2, we show a $0.42' \times 0.42'$ DESI-LS grz image of a representative galaxy from the cell (first column), as well as z_{phot}–z_{spec} plots for each of three photo-z methods: B16 (second column), `encapzulate` (third column), and random forest (fourth column). From top-to-bottom, the rows correspond to Cell A (high ⟨B/T⟩ galaxies), Cell B (low ⟨B/T⟩ galaxies), Cell C (intermediate ⟨B/T⟩ galaxies), and Cell D (very low-z galaxies). In each z_{phot}–z_{spec} panel, the solid black line corresponds to the one-to-one relation, the dashed black lines $(\Delta z/(1+z_{\text{spec}}) = \pm 0.05)$ demarcate outliers from typical data, and the red line shows the best-fit line. Both classical ML learning methods (B16 and random forest) yield flatter best-fit lines than the deep learning algorithm (`encapzulate`). The B16 photo-z's for Cell D suffer from a very high catastrophic outlier rate, which is not an issue for the other two methods.

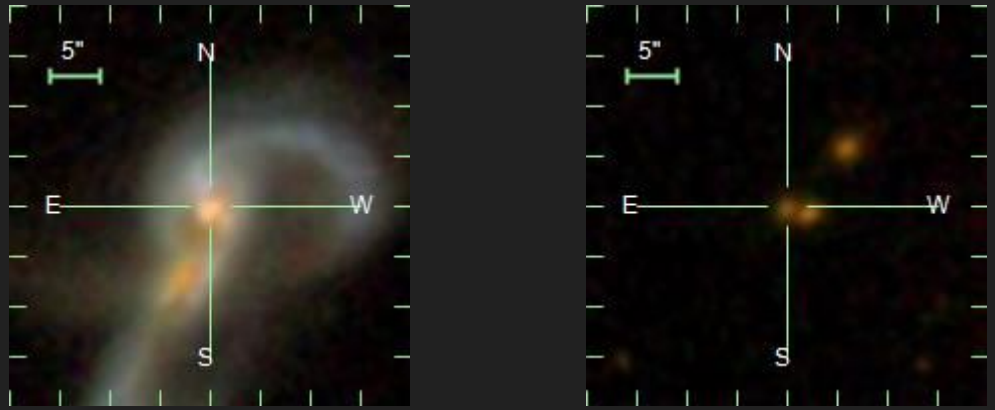
[4] Ting, Y.-S. (2025). Why Machine Learning Models Systematically Underestimate Extreme Values

Обзор решений. Наборы данных

- фотометрические признаки из обзоров
  - SDSS
  - Pan-STARRS
  - DECaLS
  - WISE
- целевая переменная получена спектроскопией
- морфологические признаки – опционально

Обзор решений. Наборы данных

- изображения галактик в различных фильтрах из обзоров
- целевая переменная получена спектроскопией



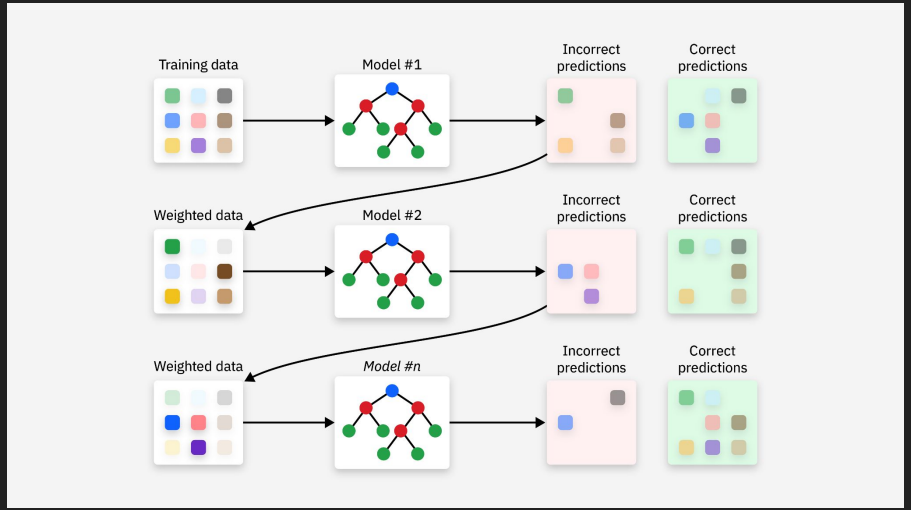
изображения с последнего обзора SDSS https://skyserver.sdss.org/dr19

Обзор решений. Набор данных. Выводы

- Неравномерное распределение переменных
- Фотометрический шум
- Изображения содержат морфологическую, пространственную информацию
- Выбраны наборы данных на основе фотометрических признаков (Teddy, Happy, SRGz) и изображений из последних обзоров

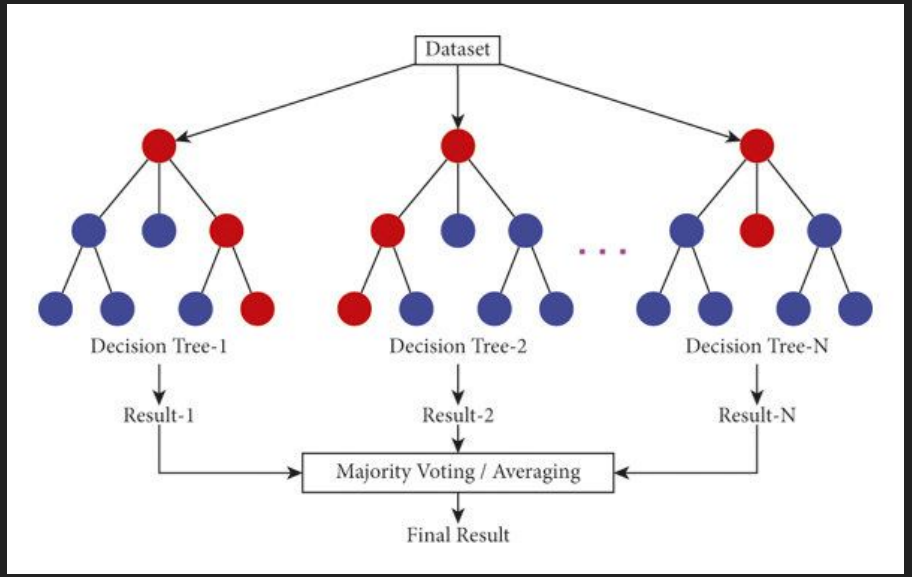
Обзор решений. Классическое машинное обучение

- CatBoost
  - градиентный бустинг над решающими деревьями
    - последовательность деревьев постепенно уточняют разбиение признакового пространства
    - каждый следующий ансамбль исправляет ошибку предыдущего
  - эффективен на табличных данных с нелинейными зависимостями
  - не требует нормализации
  - устойчив к выбросам



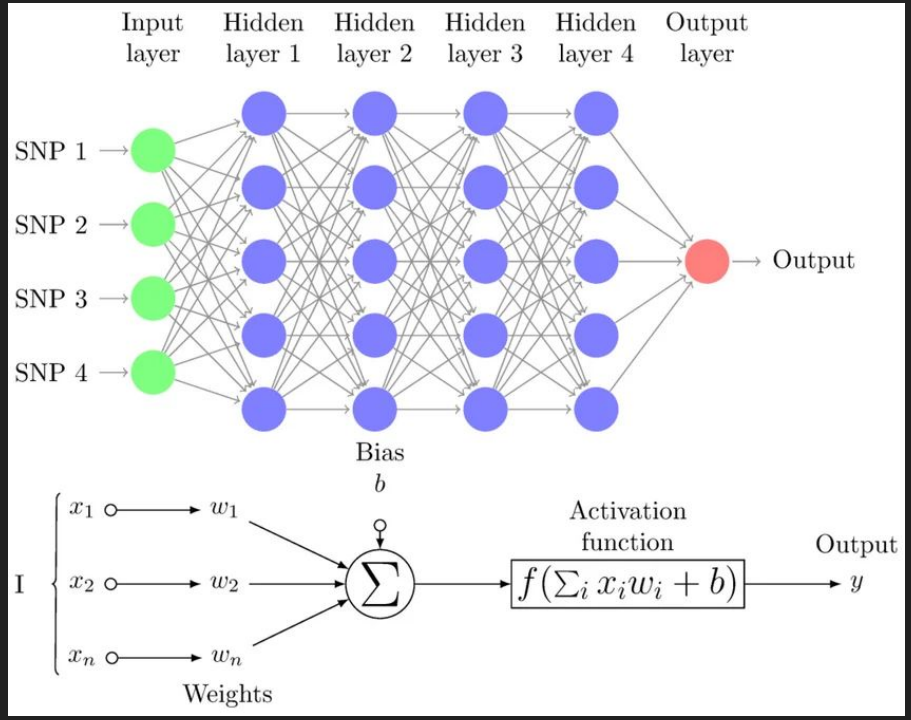
Обзор решений. Классическое машинное обучение

- RandomForest
  - ансамбль деревьев решений
  - обучение на случайных подвыборках
  - обучение на случайных признаках
  - усреднение снижает переобучение



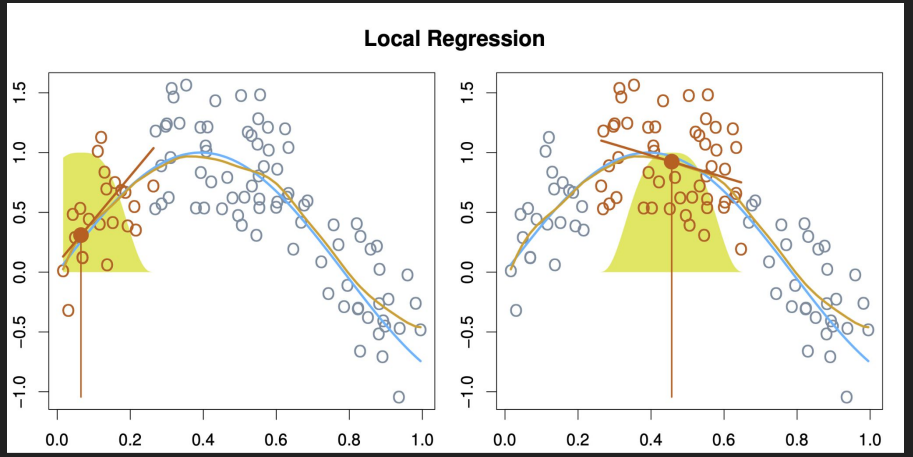
Обзор решений. Классическое машинное обучение

- MultiLayerPerceptron
  - полносвязная нейросеть
  - требует нормализации
  - аппроксимирует гладкую нелинейную зависимость
  - обычно хуже на табличных данных



Обзор решений. Классическое машинное обучение

- LocalLinearRegression
  - линейная регрессия на основе информации от соседей
  - предполагает, что соседние галактики должны быть схожими
  - устойчив к экстраполяции



Обзор решений. Классическое машинное обучение

- Идея GAM: аппроксимировать целевую переменную как сумму независимых гладких функций от каждого признака:
- каждая f — сплайн, подбираемый независимо
- модель глобальная: функции f определены на всём диапазоне признака, в том числе за пределами обучающего распределения
- нет взаимодействий между признаками (в отличие от деревьев)

$$g(\mathrm{E}(Y)) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_m(x_m).$$

Обзор решений. Нейронные сети. ConvNeXt

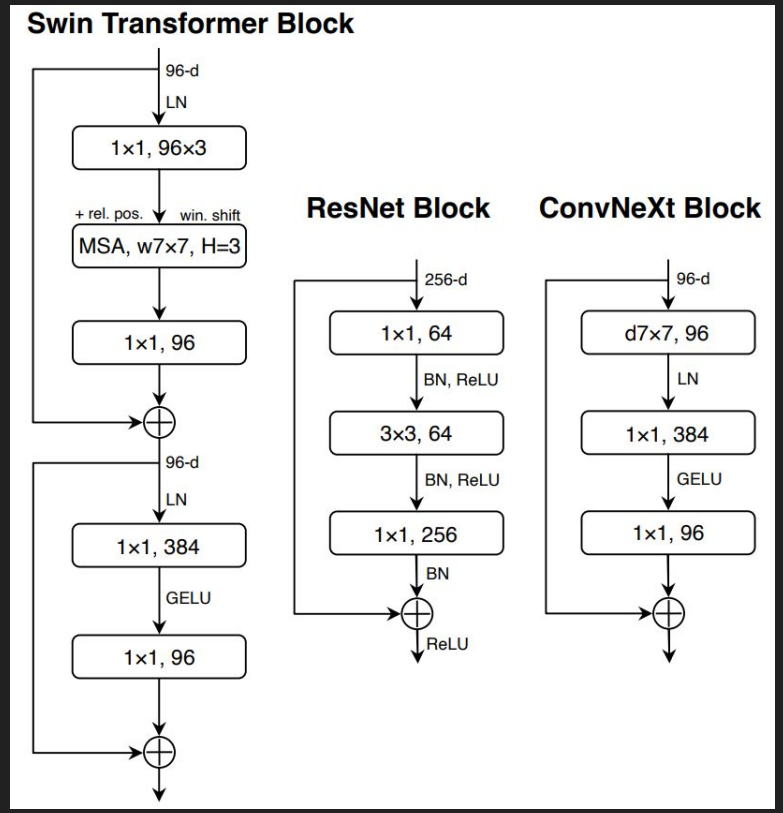
Идея: «осовременить» классическую свёртку, переосмыслив ResNet в стиле Vision Transformer

Ключевые изменения:

- depthwise separable conv 7×7 вместо 3×3 - большее рецептивное поле
- перестановка слоёв: нормализация перед активацией (как в Transformer)
- замена ReLU на GELU, BatchNorm на LayerNorm
- «перевёрнутое» соотношение каналов в блоке (как в MLP-блоке трансформера)

Преимущества:

- сохраняет эффективность обычных свёрток (нет attention - быстрее ViT)
- лучше обобщается при сдвиге распределения, чем классический ResNet/EfficientNet
- легко масштабируется



Обзор решений. Нейронные сети. EfficientNet

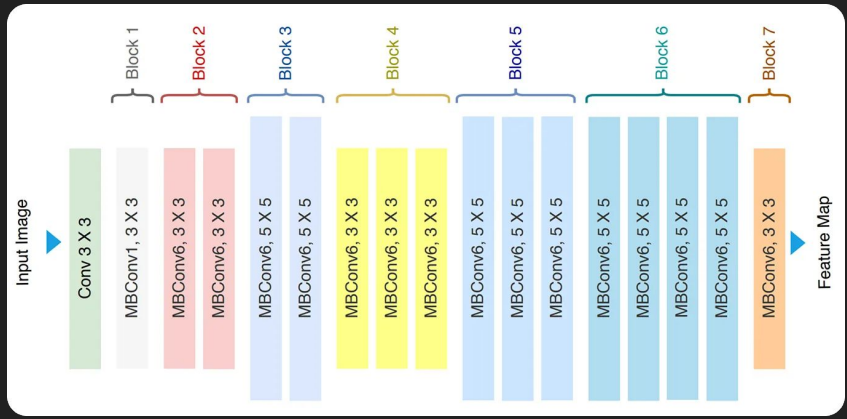
Идея: масштабировать сеть сразу по трём измерениям — глубина, ширина, разрешение входа в фиксированном соотношении

Ключевые особенности:

- основной блок — MBConv (mobile inverted bottleneck) с squeeze-and-excitation
- параметры масштабирования подобраны через Neural Architecture Search
- B0 — базовая (наименьшая) версия семейства

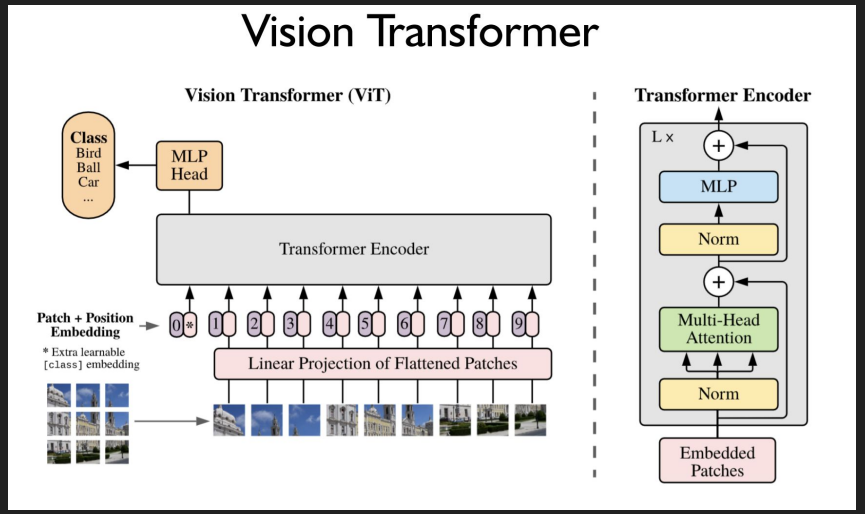
Преимущества:

- высокая точность при малом числе параметров
- хорошо работает на стандартных распределениях



Обзор решений. Нейронные сети. ViT

- Идея:
  - изображение делится на патчи (eg 16x16)
  - патч преобразуется в вектор
  - патчи передается в Transformer Encoder
  - выходной вектор используется для предсказания
- Преимущества:
  - учитывает зависимости на всем изображении



Multi-Head Self-Attention

$$[q, k, v] = zU_{qkv}, \qquad z \in \mathbb{R}^{N \times D},\ U_{qkv} \in \mathbb{R}^{D \times 3D_h}$$

$$A = \text{softmax}(qk^T / \sqrt{D_h}), \qquad A \in \mathbb{R}^{N \times N}$$

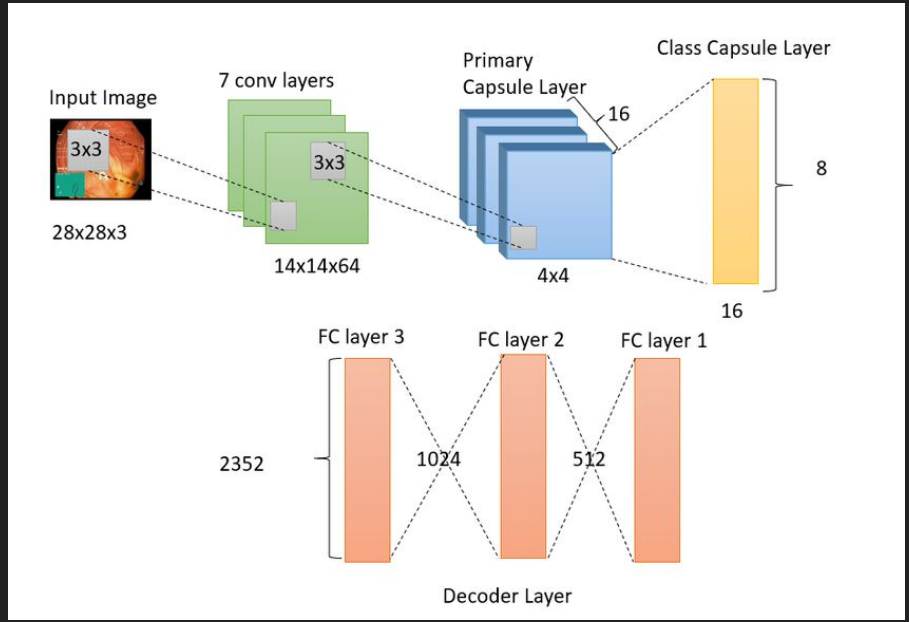
$$\text{SA}(z) = Av$$

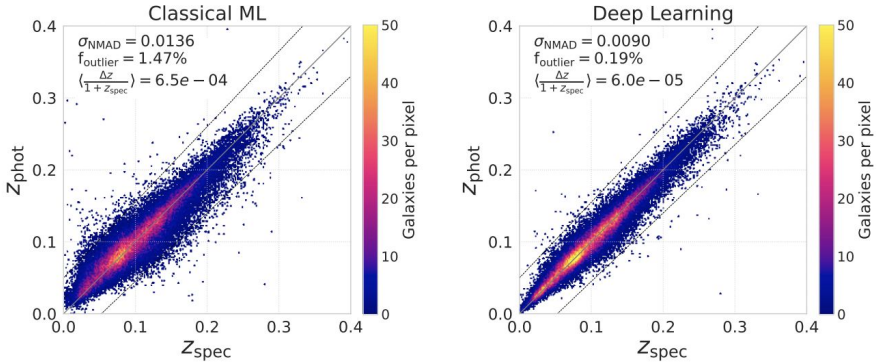
$$\text{MSA}(z) = [\text{SA}_1(z); \text{SA}_2(z); \dots; \text{SA}_k(z)]U_{msa}, \qquad U_{msa} \in \mathbb{R}^{k \cdot D_h \times D}$$

Обзор решений. Нейронные сети. CapsNet

Отличия от сверточных архитектур:

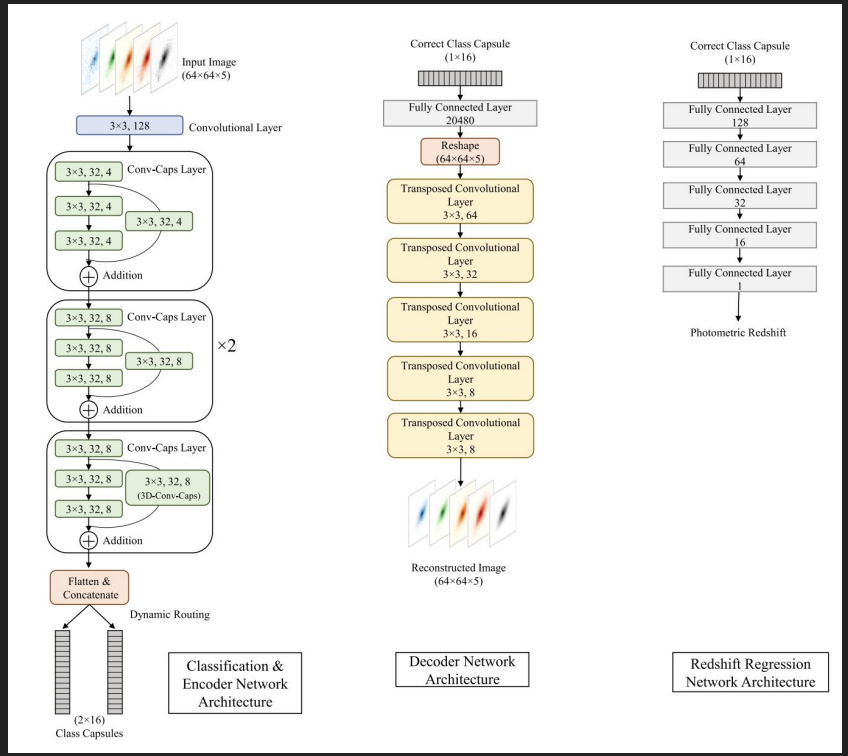
- векторные активации вместо скалярных
- dynamic routing вместо pooling





Слева – LocalLinerRegression [6], справа – энкодер на основе CapsNet [7]

- энкодер – CapsNet
- декодер не участвует на инференсе, используется для регуляризации
- выигрывает CapsNet [5]



Procedure 1 Routing algorithm.

1: **procedure** ROUTING($\hat{\boldsymbol{u}}_{j|i}, r, l$)
2: for all capsule i in layer l and capsule j in layer $(l+1)$: $b_{ij} \leftarrow 0$.
3: **for** r iterations **do**
4: for all capsule i in layer l: $\mathbf{c}_i \leftarrow \texttt{softmax}(\mathbf{b}_i)$ ▷ `softmax` computes Eq. 3
5: for all capsule j in layer $(l+1)$: $\mathbf{s}_j \leftarrow \sum_i c_{ij} \hat{\mathbf{u}}_{j|i}$
6: for all capsule j in layer $(l+1)$: $\mathbf{v}_j \leftarrow \texttt{squash}(\mathbf{s}_j)$ ▷ `squash` computes Eq. 1
7: for all capsule i in layer l and capsule j in layer $(l+1)$: $b_{ij} \leftarrow b_{ij} + \hat{\mathbf{u}}_{j|i} . \mathbf{v}_j$
return $\mathbf{v}_j$

[5] Moran, E. R., Andrews, B. H., Newman, J. A., & Dey, B. (2022). Deep Learning Improves Photometric Redshifts in All Regions of Color Space

[6] Dey, B., Andrews, B. H., Newman, J. A., Mao, Y.-Y., Rau, M. M., & Zhou, R. (2022). Photometric redshifts from SDSS images with an interpretable deep capsule network

[7] Beck, R., Dobos, L., Budavári, T., Szalay, A. S., & Csabai, I. (2016). Photometric redshifts for the SDSS Data Release 12

Обзор решений. Алгоритмы. Выводы

- Выбраны алгоритмы классического машинного обучения
  - CatBoost
  - RandomForest
  - MultiLayerPerceptron
  - LocalLinearRegression
  - GAM
- Выбраны алгоритмы глубокого обучения:
  - VisionTransformer
  - CapsNet
  - ConvNext
  - EfficientNet
- Глубокое обучение на изображениях
  - учитывают пространственную информацию
  - устойчивы к attenuation bias

Обзор решений. Метрики

- Метрика задачи регрессии:

$$RMSE = \sqrt{\frac{1}{N}\sum\left(z_{pred} - z_{gt}\right)^2}$$

- Catastrophic outlier fraction – процент выбросов:

$$f_{outlier} = \frac{|z_{pred} - z_{gt}|}{1 + z_{gt}} \geq 0.15$$

- Нормализованное медианное абсолютное отклонение:

$$\sigma_{NMAD} = 1.48 \cdot median\left(\left|\frac{z_{pred} - z_{gt}}{1 + z_{gt}} - bias\right|\right)$$

- Сдвиг:

$$bias = median\left(\frac{z_{pred} - z_{gt}}{1 + z_{gt}}\right)$$

Исследование и решение задачи

- Подзадачи:
  - разработка экспериментального стенда
  - исследование моделей на разных выборках
    - Teddy
    - Happy
    - SRGz
  - итоги, выводы

Экспериментальный стенд

- Требования
  - прозрачночть
  - переносимость, воспроизводимость
  - расширяемость
  - эффективные вычисления

catboost_fast_test.yaml 633 B

```yaml
split:
  val_size: 0.25
  shuffle: true
  random_seed: 42

estimator: |
  from sklearn.pipeline import Pipeline
  from catboost import CatBoostRegressor

  estimator = Pipeline([
    ("model", CatBoostRegressor(
      loss_function="RMSE",
      random_seed=42,
      verbose=False,
      allow_writing_files=False,
      thread_count=-1
    ))
  ])

estimator_params: {}

hyperopt:
  enabled: false
  cv: 3
  scoring: "neg_root_mean_squared_error"
  n_jobs: 1
  verbose: 1

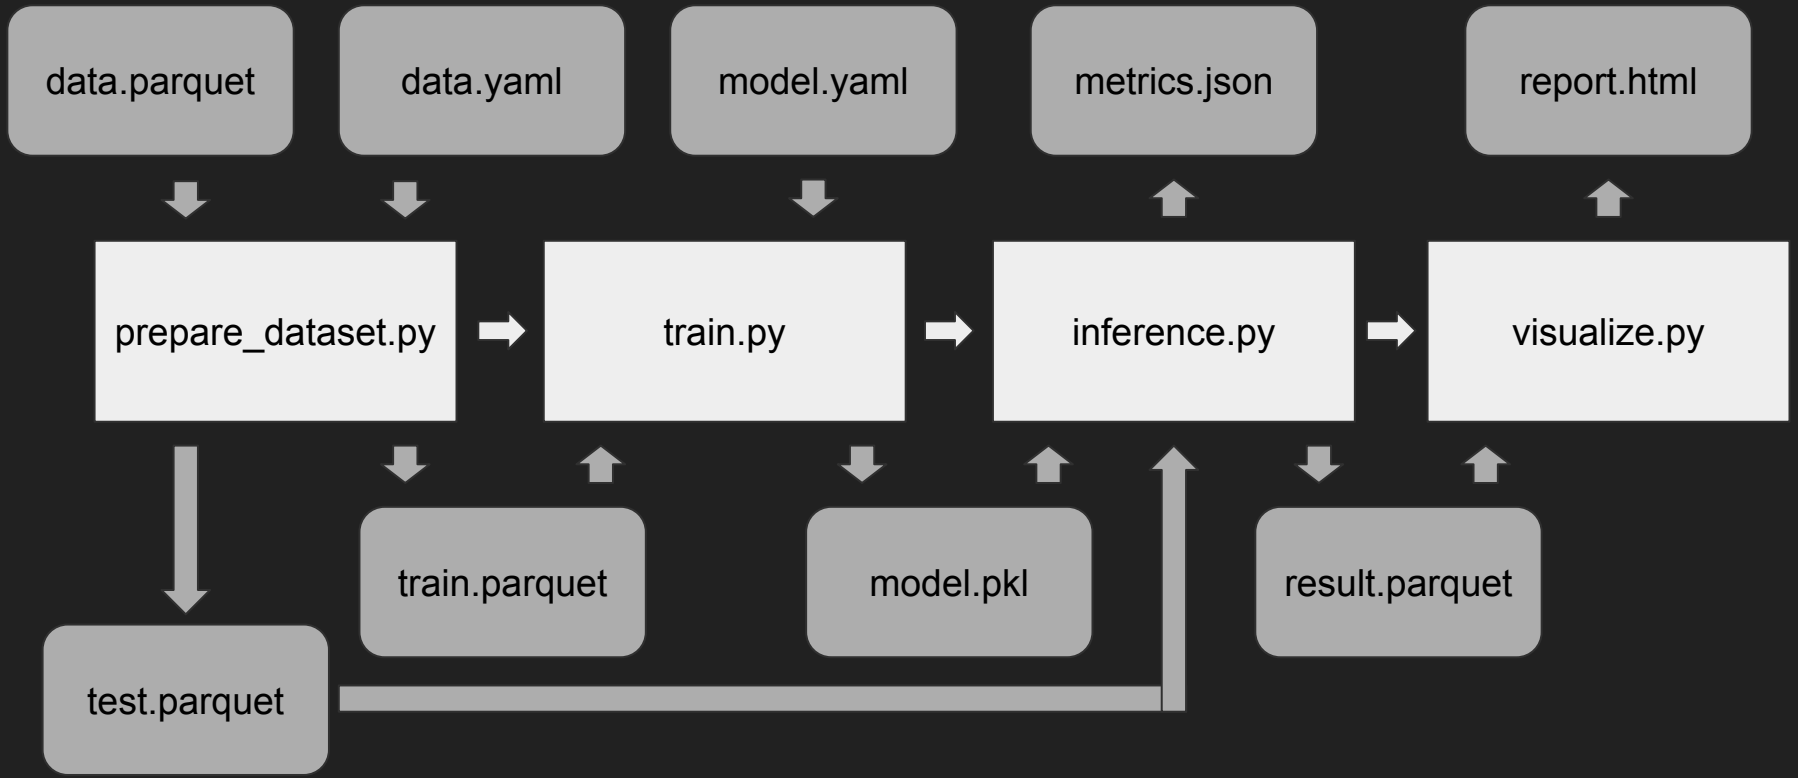
param_grid:
  "model__iterations": [100, 200, 300]
  "model__depth": [6, 7, 8]
  "model__learning_rate": [0.01, 0.03, 0.05]
  "model__l2_leaf_reg": [1, 3, 5]

```

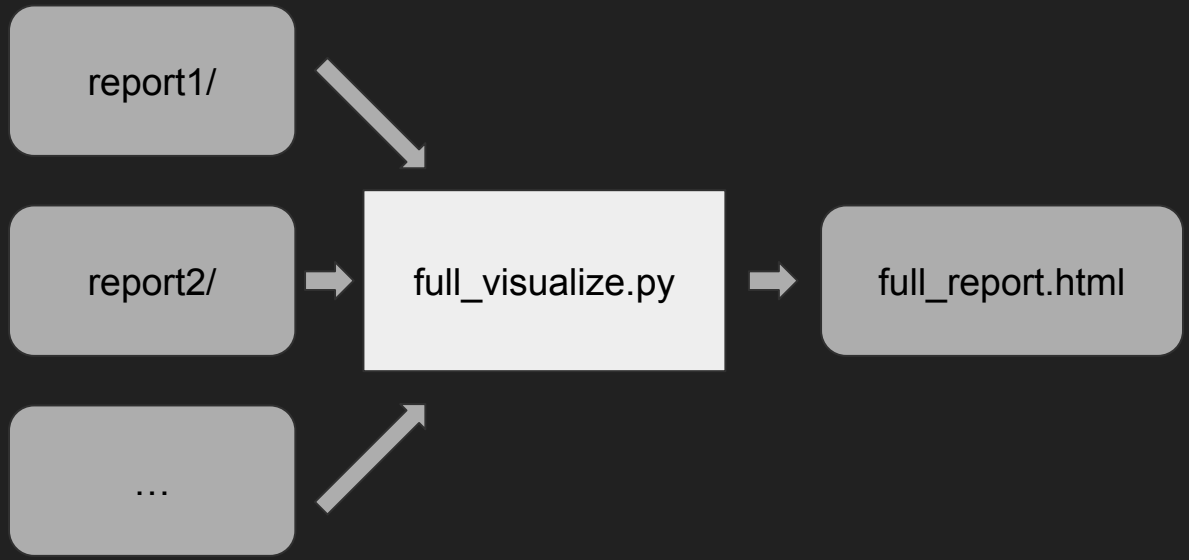
Экспериментальный стенд

- Функциональность
  - загрузить набор данных из S3-совместимого хранилища
  - обработать его – удалить неиспользуемые столбцы
  - разделить на тестовую/обучающую выборки исходя из конфигурации
  - обучение моделей исходя из конфигурации
    - перебор гиперпараметров
    - кросс-валидация
  - применение моделей на тестовой выборке
  - подсчет метрик качества
  - визуализация – таблица с метриками, графики
  - общая сводная таблица всех экспериментов

Экспериментальный стенд



Экспериментальный стенд

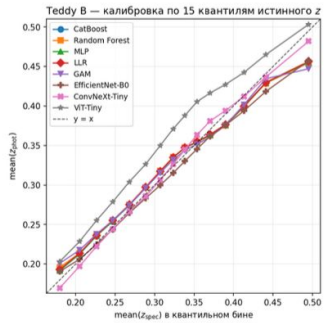


Наборы данных

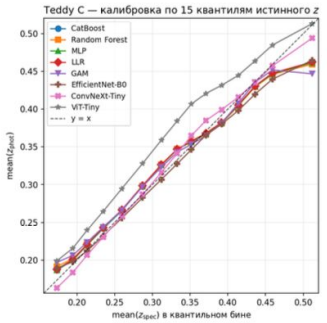
Название	Teddy	Happy	SRGz
Размер	A, B, D = 75,000 C = 100,000	A, B, D = 75,000 C = 60,000	300,000
Тип объектов	Оптические, инфракрасные	Оптические, инфракрасные	Рентгеновские
Обзор	SDSS	SDSS	SDSS, DESI, Pan-STARRS, DECaLS
Признаки, их тип	фотометрические признаки (u, g, r, i, z) – числовые	фотометрические признаки (u, g, r, i, z) – числовые	фотометрические признаки (u, g, r, i, z) – числовые
Целевая переменная	photo-z	photo-z	photo-z
Обучающая/ тестовая выборки	A – обучающая; B, C, D – тестовые	A – обучающая; B, C, D – тестовые	Делится в соотношении 80/20

Проведение экспериментов. Результаты на Teddy

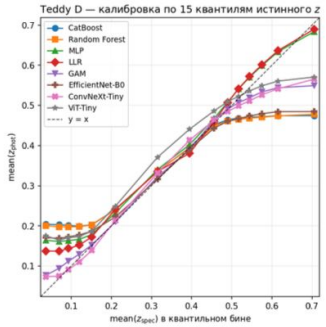
Модель	TeddyB		TeddyC		TeddyD	
	σ_{NMAD}	f_{out}, %	σ_{NMAD}	f_{out}, %	σ_{NMAD}	f_{out}, %
CatBoost tab	**0.0170**	0.18	0.0170	0.27	0.0764	8.14
Random Forest tab	0.0174	0.18	0.0174	0.26	0.0790	6.00
MLP tab	0.0171	0.17	**0.0170**	0.25	0.0396	3.23
LLR tab	0.0171	0.18	0.0170	0.26	0.0360	3.71
GAM tab	0.0199	0.10	0.0205	0.17	**0.0329**	2.16
— модели на изображениях —						
EfficientNet-B0 nn	0.0204	0.12	0.0209	0.17	0.0662	4.35
ConvNeXt-Tiny nn	0.0228	0.51	0.0236	0.59	0.0346	2.35
ViT-Tiny nn	0.0413	1.11	0.0408	1.11	0.0483	5.39



(a) TeddyB



(b) TeddyC



(c) TeddyD

Рисунок 22 — Калибровочные кривые на подвыборках Teddy.

- TeddyB, TeddyC – приблизительно одинаковы по качеству (B == A)
- TeddyD – сильная деградация
  - наилучшая устойчивость к экстраполяции – llr, mlp, gam, convnext
  - худшая – остальные

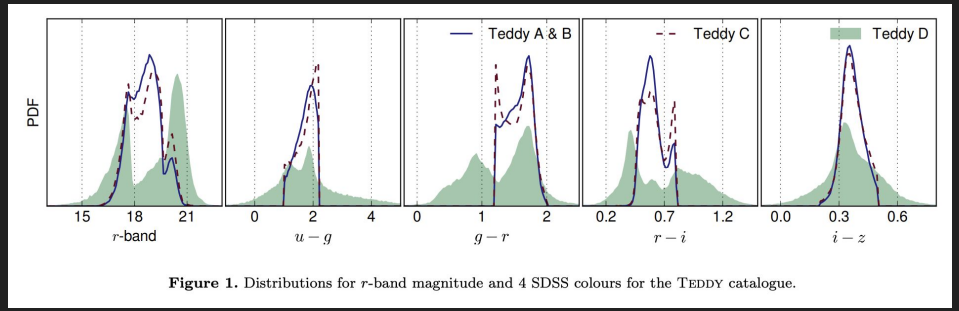
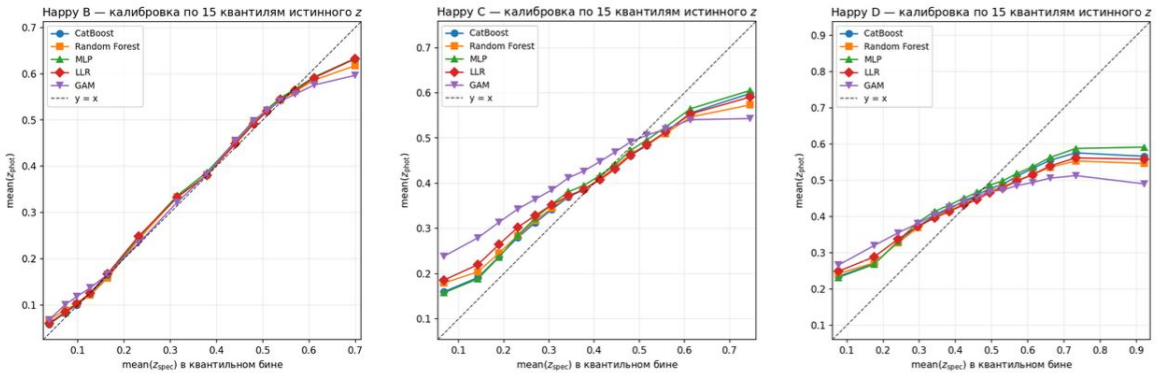


Figure 1. Distributions for r-band magnitude and 4 SDSS colours for the TEDDY catalogue.

Проведение экспериментов. Результаты на Happy

Модель	HappyB		HappyC		HappyD	
	σ_{NMAD}	f_{out}, %	σ_{NMAD}	f_{out}, %	σ_{NMAD}	f_{out}, %
CatBoost tab	**0.0207**	1.01	**0.0515**	5.86	0.0810	15.21
Random Forest tab	0.0228	1.07	0.0553	5.78	0.0823	14.13
MLP tab	0.0213	0.97	0.0529	5.85	**0.0809**	14.37
LLR tab	0.0208	1.14	0.0554	6.50	0.0839	14.53
GAM tab	0.0328	1.63	0.0758	11.61	0.1062	18.86



(a) HappyB (b) HappyC (c) HappyD

Рисунок 23 — Калибровочные кривые на подвыборках Happy.

- HappyB, HappyC, HappyD
  - модели одинаково деградируют
  - одинаковая скорость деградации
  - хорошо видно смещение к среднему

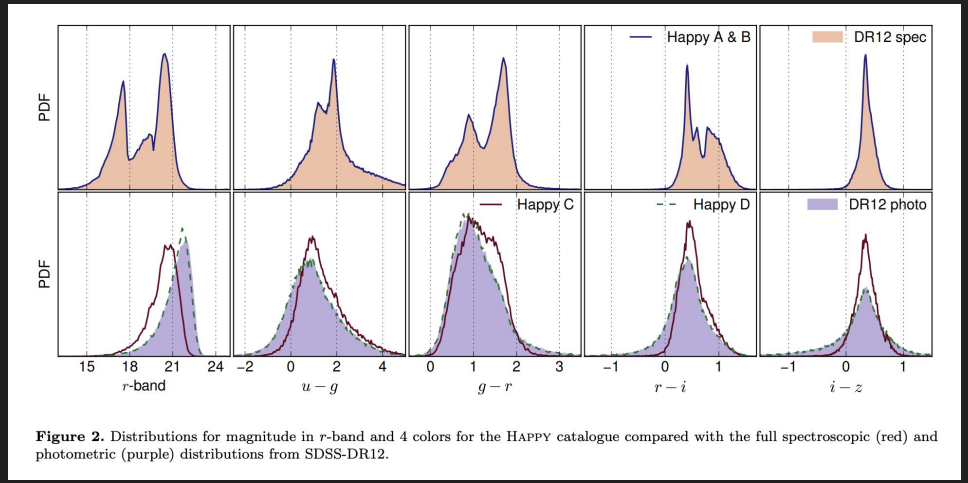
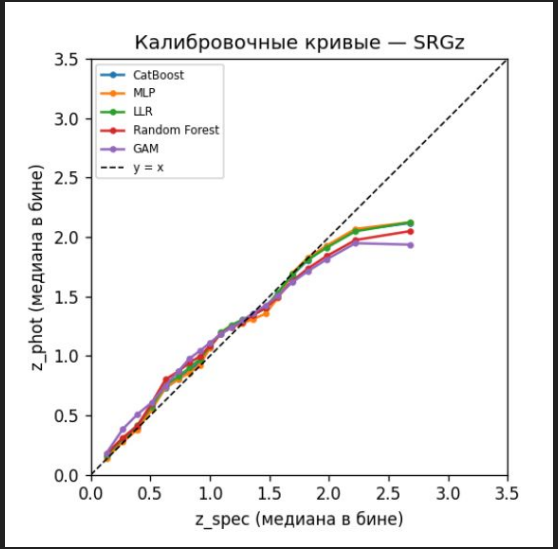


Figure 2. Distributions for magnitude in r-band and 4 colors for the HAPPY catalogue compared with the full spectroscopic (red) and photometric (purple) distributions from SDSS-DR12.

Проведение экспериментов. Результаты на SRGz

Модель	σ_{NMAD}	f_{out}, %	bias ($\times 10^{-2}$)
tab MLP	**0.0773**	14.17	-0.109
tab CatBoost	0.0797	15.50	0.463
tab LLR	0.0801	17.19	1.063
tab Random Forest	0.0919	19.13	0.999
tab GAM	0.1304	28.47	1.019



Проведение экспериментов. Выводы

- Алгоритмы классического машинного обучения показывают плохое качество
- Причины:
  - domain shift
  - зашумленность наблюдений
  - attenuation bias
  - плотное скопление галактик
- Алгоритмы глубокого обучения на изображениях не улучшают качество на Teddy

Планы на будущее

- Реализация CapsNet
- Тестирование подходов к разделению членов соседних скоплений на основе фотометрических красных смещений
- Перенос наиболее удачных решений на SRGz